

Metody Monte Carlo

Raport 3

Autor: Anna Bonikowska

06.05.2024

Spis treści

1	Problem 1 – Generowanie rozkładów warunkowych i wielowymiarowych	2
2	Problem 2 – Przybliżone obliczanie całek metodą Monte Carlo	10
3	Problem 3 – Twierdzenia graniczne dla ciągów <i>i.i.d.</i>	13

1 Problem 1 – Generowanie rozkładów warunkowych i wielowymiarowych

- Niech $X \sim \text{Bin}(1, p)$ i $Y|X = 0 \sim N(0, 1)$, $Y|X = 1 \sim N(\mu, \sigma)$, gdzie $p \in [0, 1]$, $\mu \in \mathbb{R}$, $\sigma > 0$. Zaimplementuj generator zmiennej Y . Uzasadnij, że $Y \sim (1-p)N(0, 1) + pN(\mu, \sigma)$. Narysuj histogram i wykresy funkcji gęstości tego rozkładu dla wybranych parametrów.
- Zaproponuj sposób generacji punktów z rozkładu jednostajnego na sympleksie $S := \mathbb{R}^2 \cap \{x, y > 0, x + y < 1\}$ oraz z rozkładu o gęstości cxy^2 na S .
- Zaimplementuj generator rozkładu $N(\mu, \Sigma)$, gdzie $\mu = (1, -1, 0)$ i $\Sigma = \begin{bmatrix} 2 & 2 & 0 \\ 2 & 5 & -3 \\ 0 & -3 & 9 \end{bmatrix}$.

Sprawdź, czy Σ jest symetryczna i dodatnio określona. Dla obliczenia $\Sigma^{1/2}$ użyj zaimplementowanej w R metody Choleskiego lub rozkładu spektralnego macierzy Σ . Wygeneruj próbkę z tego rozkładu i zilustruj wszystkie rozkłady 1-wymiarowe, 2-wymiarowe i 3-wymiarowe. Ile ich jest?

Rozwiązanie:

- Generator rozkładu $Y \sim (1-p)N(0, 1) + pN(\mu, \sigma)$

```
generator_Y<-function(n, p, mi, gam){
  u <- runif(n )

  x <- c()


  for( i in u){

    if(i<p){
      x<- c(x,rnorm(1, mean=mi,sd=(gam)**(1/2)))
    } else {
      x<- c(x,rnorm(1, mean=0,sd=1))
    }
  }


  return(x[])
}
```

$$\begin{aligned}
 &X \sim \text{Bin}(1, p) \\
 &\text{Zobaczmy } X=0, X=1 \text{ są rozłożone} \\
 &\text{niezależnie: } \Omega \\
 &\mathbb{P}(Y \in A) = \mathbb{P}(Y \in A | X=0) \mathbb{P}(X=0) + \mathbb{P}(Y \in A | X=1) \mathbb{P}(X=1) \\
 &= \mathbb{P}(Z \in A) \cdot (1-p) + \mathbb{P}(H \in A) \cdot p \\
 &\quad Z \sim N(0, 1) \quad H \sim N(\mu, \sigma) \\
 &\text{bo } Y|X=0 \sim N(0, 1) \quad Y|X=1 \sim N(\mu, \sigma) \\
 &\text{Więc } Y \sim (1-p)N(0, 1) + pN(\mu, \sigma)
 \end{aligned}$$


Uzasadnienie, że $Y \sim (1-p)N(0, 1) + pN(\mu, \sigma)$



Rysunek 1: Generator rozkładu Y dla parametrów $p=0.2$, $\mu=3$, $\sigma=1$



Rysunek 2: Generator rozkładu Y dla parametrów $p=0.9$, $\mu = 10$, $\sigma = 4$



Rysunek 3: Generator rozkładu Y dla parametrów $p=0.5$, $\mu = -2$, $\sigma = 0.5$

- generowanie rozkładu jednostajnego na symplexie:

```
# zwraca macierz gdzie x[i,1] odpowiada współrzędnej x
#a x[i,2] odpowiada współrzędnej y punktu i
gener1 <- function(n){
```

```
  licznik<- 0
  x <- c()
  y <- c()
```

```
  while (licznik<n){
```

```
a <-runif(1)
b <-runif(1)

if ((a+b)<1){
  #print(a)
  #print(b)
  #print(a+b)
  #print(3)

  licznik <- licznik + 1

  x <- c(x,a)
  y <- c(y,b)

}

}

u_matrix <- matrix(c(x,y), ncol=2)

return(u_matrix)
}
}
```

generowanie rozkładu cxy^2 na S :

```
# zwraca macierz gdzie x[i,1] odpowiada współrzędnej x
#a x[i,2] odpowiada współrzędnej y punktu i
gener2 <- function(n){
```

```
  licznik<- 0
  x <- c()
  y <- c()

  while (licznik<n){

    u1 <-runif(1)
    u2 <-runif(1)

    x2 <- u1**(1/2)
    y2 <- u2**(1/3)

    if ((x2+y2)<1){
      #print(a)
      #print(b)
```

```

    #print(a+b)
    #print(3)

    licznik <- licznik + 1

    x <- c(x,x2)
    y <- c(y,y2)

  }

}

u_matrix <- matrix(c(x,y), ncol=2)

return(u_matrix)

}

```

- – Σ jest symetryczna. Sprawdza sie to wprost
- sprawdzanie czy Σ jest dodatnio okreslona. Jesli Σ ma dodatnie wartosci własne to jest dodatnio okreslona

```

A <- matrix(c(2,2,0,2,5,-3,0,-3,9), ncol=3)

eigen(A)

```

```

eigenvalues <- eigen(A)$values

# Sprawdzenie czy wszystkie wartości własne są dodatnie
all_positive_eigenvalues <- all(eigenvalues > 0)
all_positive_eigenvalues

```

- generator rozkładu $N(\mu, \Sigma)$

```

gener_wielow_norm <- function(mean, cov_matrix, num_samples) {

  B <- t(chol(cov_matrix))

  z <- matrix(rnorm(length(mean) * num_samples), nrow = length(mean))

  samples <- matrix(mean, ncol=num_samples, nrow=length(mean)) + B %*% z



  return(samples)


}

```


```
#generuje rozkład N(mi, Sigma)
x <- gener_wielow_norm(mean = c(1,-1,0), cov_matrix = matrix(c(2,2,0,2,5,-3,0,-
```



– rozkłady dwuwymiarowe:





– rozkłady jednowymiarowe





2 Problem 2 – Przybliżone obliczanie całek metodą Monte Carlo

- Aproksymuj metodą Monte Carlo całkę $\int_0^1 e^{-x^2} dx$. Zbadaj empirycznie szybkość zbieżności i wariancję otrzymanego estymatora w zależności od rozmiaru próby. Znajdź przedział ufności dla tej całki na podstawie $n = 1000$ obserwacji.
- Użyj metody Monte Carlo do aproksymacji całki $\int_0^\infty x^5 e^{-x} \cos x dx$.
- Metodą Monte Carlo oszacuj powierzchnię żuka Mandelbrota. Jak ocenić błąd?

Rozwiązanie:

- aproksymowanie całki $\int_0^1 e^{-x^2} dx$:

```
fun <- function(n){  
  I <- 0  
  
  for (i in 1:n){  
    u <- runif(1)  
  
    I <- I + exp(-u**2)  
  
  }  
  
  I <- I/n  
  
  return(I)  
}
```

wartość obliczona przez internetowy kalkulator całek:

0.7468241328124270253994674361318530053544996868126063290276544989...

...

dla próby n=10:

mean=0.7470848 var= 0.004037572

dla próby n=100:

mean=0.746775 var=0.0004151597

dla próby n=1000:

mean=0.746892 var=3.999278e-05

dla próby n=10000:

mean=0.7468265 var=4.038532e-06

- aproksymacja całki $\int_0^\infty x^5 e^{-x} \cos x dx$

```

fun <- function(n){
  I <- 0

  for (i in 1:n){
    x <- rexp(1, rate=1)

    I <- I + x**5*cos(x)

  }

  I <- I/n

  return(I)
}

```

$$\int_0^\infty x^5 e^{-x} \cos x dx \approx 0.1629284$$

gdyn = 100000000

według Wolfram Alpha: $\int_0^\infty x^5 e^{-x} \cos x dx = 0$

- aproksymacja powierzchni rzeka mandelbrota

funkcja sprawdzająca czy punkt należy do zbioru rzeka mandelbrota:

```

mandelbrot <- function(a,b){

  c <- 0
  d <- 0
  czy_nalezy <- 0
  i <- 0
  wynik <- 0

  while( i <= 1000 & wynik < 2 ){

    x <- c^2 - d^2 + a
    y <- 2*d*c + b

    c<-x
    d <-y

    i <- i +1

    wynik <- (c^2 + d^2)^(1/2)
  }
}

```

```
}  
  
wynik <- (c^2 + d^2)^(1/2)  
  
czy_nalezy <- 0  
  
if( wynik < 2){  
  czy_nalezy <- 1  
}  
  
return( czy_nalezy)  
}
```

właściwa funkcja licząca pole powierzchni Mandelbrota

```
fun <- function(n){  
  I <-0  
  
  for (i in 1:n){  
    x <- runif(1,min=-2, max=1)  
    y <- runif(1,min=-1, max=1)  
  
    I <- I + 6*mandelbrot(x,y)  
  
  }  
  
  I <- I/n  
  
  return(I)  
  
}
```

Nie da się wprost oszacować błędu bo nie jest znana dokładna wartość powierzchni zbioru Mandelborta, ale jest szacowana na 1.3744 do 1.68288. Wartości mojej funkcji mieszczą się w tym przedziale czyli moja funkcja działa z grubsza dobrze.

3 Problem 3 – Twierdzenia graniczne dla ciągów *i.i.d.*

- Udowodnij słabe prawo wielkich liczb, gdy $\mathbb{E}X^2 < \infty$.
- Sformułuj mocne prawo wielkich liczb. Zilustruj je symulacjami, gdy $X \sim \text{Bin}(1, p)$.
- Sformułuj Centralne Twierdzenie Graniczne dla średnich i sum *i.i.d.* zmiennych losowych o skończonym drugim momencie. Korzystając z CTG i tablic dystrybuanty rozkładu normalnego oblicz w przybliżeniu $\mathbb{P}(U_1 + \dots + U_n > 0.5n + 0.1\sqrt{n})$ dla (*i.i.d.*) zmiennych losowych U_1, \dots, U_n z rozkładu jednostajnego. Zweryfikuj i zilustruj ten wynik przez symulacje.

Rozwiązanie:

- mocne prawo wielkich liczb

X_1, X_2, \dots, X_n *i.i.d.*

$\mathbb{E}(|X_1|) < \infty$

$\lim_{n \rightarrow \infty} \frac{1}{n} \sum_{i=1}^n X_i = \mathbb{E}(X_1)$ z prawdopodobieństwem 1

```
sum <- 0
p<-0.9
```

```
n <- 1000000
```

```
for (i in 1:n){
```

```
  x <- rbinom(1,size=1, prob=p)
```

```
  sum <- sum + x
```

```
}
```

```
sum<- sum/n
```

```
sum
```

wartosc oczekiwana to p=0.9 sum= 0.8999617 Czyli jest to zbiezne czyli zachodzi prawo wielkich liczb

- Centralne Twierdzenie Graniczne dla średnich i sum

Jeżeli

(X_i)

jest ciągiem niezależnych zmiennych losowych o tym samym rozkładzie, $\mathbb{E}(|X_1|) = \mu < \infty, \text{Var} x_i = \sigma^2 < \infty$ to

$$\lim_{n \rightarrow \infty} \mathbb{P}\left(\frac{X_1 + X_2 + \dots + X_n - n\mu}{\sigma\sqrt{n}} \leq x\right) = N \sim N(0, 1)$$

Według moich obliczeń:

$$\mathbb{P}(U_1 + \dots + U_n > 0.5n + 0.1\sqrt{n}) = 0,3669$$

symulacyjne obliczenie $\mathbb{P}(U_1 + \dots + U_n > 0.5n + 0.1\sqrt{n})$:

```

sprawdzanie <- function(n){

  h <- 10000

  x <- 0

  for (i in 1:h){

    u <- runif(n)

    if ( sum(u) > 0.5*n +0.1*n**(1/2)){

      x<- x+1
    }

  }

  return(x/h)

}

```

Dla $n=10000000$ wyszło że ta wartosc wynosi 0.3688. To jest całkiem dobre przybliżenie